

딥러닝 기반의 나사 결함 탐지 모델 성능 비교에 관한 연구

허민엽

동아대학교 소프트웨어대학 컴퓨터공학과

A study on the performance comparison of deep learning-based screw defect detection models

abstract

본 연구는 제조 현장의 극심한 클래스 불균형 환경에서 실시간 나사 결함 탐지에 최적화된 딥러닝 모델을 선정하기 위해 수행되었다. VGG-16, ResNet-18, MobileNet-V2에 전이학습을 적용하였으며, Weighted Cross Entropy Loss 함수를 적용하여 3.25:1의 데이터 불균형을 해소하였다. Stratified 5-Fold CV으로 최적 가중치를 탐색한 후 전체 데이터 재학습을 수행하였고, F2-score와 FPS를 통합한 지표 FASI로 최종 성능을 평가하였다. 실험 결과, ResNet-18이 최적 가중치 2.0에서 정확도와 속도 모두 본 실험 범위 내에서 가장 우수한 성능을 달성하여 후보 모델 중 가장 적합한 모델로 선정되었다.

keyword

결함 탐지(Defect detection), 합성곱 신경망(Convolution Neural Network), 최적 하이퍼파라미터 탐색(Grid Search CV), 데이터 불균형(Data imbalance), 데이터 증강(Data augmentation)

I. Introduction

1. 연구 배경

4차 산업혁명의 도래와 함께 제조 공정의 지능화가 가속화되고 있다. 특히 나사(Screw)와 같은 소형 체결 부품은 전자기기, 자동차 등 다양한 산업 분야의 핵심 구성 요소로, 미세한 결함도 전체 제품의 안정성과 신뢰성에 치명적인 영향을 미칠 수 있다. 기존의 육안 검사 방식은 검사자 간 판정 기준의 편차가 불가피하며, 장시간 반복 작업으로 인한 피로 누적은 결함 미탐 및 오탐 가능성을 증가시킨다. 이를 보완하기 위해 컴퓨터 비전 기술이 도입되었으나, 금속 재질 특유의 빛 반사, 나사산의 복잡한 형상, 조명 변화 등 환경적 요인으로 인해 미세하고 비정형적인 결함을 안정적으로 탐지하는 데 한계가 존재한다. 더욱이 실제 제조 공정에서는 정상 제품이 불량 제품보다 많은 클래스 불균형 문제가 발생하며, 이는 일반적인 머신러닝 기법으로는 충분한 검출 신뢰도를 확보하기 어렵게 만든다. 따라서 본 연구에서는 환경적·데이터적 한계를 극복하고, 다양한 딥러닝 모델을 비교 분석하여, 제조 현장에 적합한 최적의 나사 결함 탐지 모델을 선정하고자 한다.

2. 기존의 문제점

실제 제조 현장의 비전 검사 시스템은 정상품이 불량품보다 많은 데이터 불균형 문제에 직면한다. 이로 인해 딥러닝 모델은 전체 정확도를 높이기 위해 모든 제품을 정상으로 예측하는 경향을 보이며, 결과적으로 치명적인 불량을 놓치는 미탐 현상이 발생한다. 이를 우회하기 위해 정상 패턴만 학습하는 비지도 학습 기법이 연구되었다. 그러나 나사 특유의 미세한 빛 반사나 가공 공차 등 허용 가능한 정상 범위까지 결함으로 오인하여 정상 제품을 폐기하는 과잉 검출 비율이 높아지고, 이는 제조 현장의 수율 저하로 이어지는 한계를 보였다. 또한 불량 특징을 직접 학습시키는 지도 학습 기반 CNN 모델들 역시 파라미터가 많으면 실시간 처리 속도를 만족하지 못하고, 경량화할 경우 미세 결함 탐지 성능이 저하되는 trade-off가 존재한다. 따라서 데이터 불균형을 극복하면서도 높은 검출 성능과 실시간 처리 속도를 동시에 만족시킬 수 있는 딥러닝 아키텍처 선정 및 최적화 방안이 요구된다.


3. 본 연구의 목적

본 연구의 최종 목적은 제조 현장의 데이터 불균형 환경을 극복하고, 실시간 나사 결함 탐지에 가장 적합한 딥러닝 모델을 선정하는 데 있다. 이를 위해 대표적인 CNN 아키텍처인 VGG-16, ResNet-18, MobileNet-V2를 대상으로 동일한 실험 환경에서 성능을 비교 분석한다. 클래스 불균형 해소를 위해 Weighted Cross Entropy Loss 함수를 적용하고, 데이터 증강 기법 및 조기 종료(Early Stopping) 전략을 통해 학습 효율과 일반화 성능을 확보한다. 또한 최적 클래스 가중치 탐색을 위해 1.0부터 5.0까지 체계적인 하이퍼파라미터 스윙 실험을 수행한다. 모델 평가 시 단순 정확도(Accuracy)가 아닌 불량 미탐을 최소화하는 F2-score를 주요 지표로 활용하며, 실제 현장 배포 가능성을 검증하기 위해 CPU 기준 추론 속도(FPS)를 측정한다. 최종적으로 검출 성능과 처리 속도를 통합한 FASI(Factory Automation Suitability Index) 지표를 제안하여 제조 현장에 적합한 최적 모델을 도출한다.

II. Related Works

1. CNN의 원리와 구조


컴퓨터 비전 분야에서 획기적인 성능 향상을 이끌어낸 CNN은 인간의 신경세포에서 영감을 받아 설계된 딥러닝 알고리즘이다. 기존의 완전 연결 신경망(Fully Connected Network)은 1차원 형태로 데이터를 처리하여 이미지의 공간적 특성을 잃어버리는 한계가 있었다. 반면, CNN은 이미지의 2차원 공간 정보를 그대로 유지하면서 특징을 추출하기 때문에 표면 스크래치나 형태 변형과 같은 비정형 결함을 탐지하는 데 탁월한 성능을 발휘한다.



[그림 1] CNN 아키텍처


CNN의 핵심 구조는 크게 Convolution Layer와 Pooling Layer, Fully Connected Layer로 구성된다.

첫째, Convolution Layer는 입력 이미지에 다양한 필터(Filter 또는 Kernel)를 일정한 스트라이드(Stride)로 이동하는 방식으로 이미지의 특징을 찾는다. 합성곱(Convolution) 연산 과정에서 이미지의 외각이 한 픽셀씩 줄어드는 현상이 발생하는데 이것을 방지하기 위해 이미지 출력 형태가 입력과 동일하게 유지되는 패딩(Padding) 기능을 설정하여 영상의 크기를 한 픽셀씩 크게 하고 0 또는 평균값을 적용한다.




[그림 2] Convolution 연산

Convolution의 출력은 활성화 함수(Activation Function)로 전달되며 활성화 함수는 기울기 소실 문제 (Vanishing Gradient)가 발생하는 Sigmoid 또는 Tanh 함수와 달리 입력값이 음수일 때 0을 출력하고 양수일 때 입력된 값을 그대로 출력하는 ReLu 함수를 일반적으로 적용한다.




[그림 3] Sigmoid, ReLu 함수

둘째, 풀링층은 추출된 특징 맵의 크기를 절반으로 줄여 연산량을 줄인다. CNN에서는 주로 사용되는 맥스풀링(Maxpooling) 레이어는 영역 내에서 최대 픽셀 값을 취하는 방식으로 이미지 특징을 추출하면서 이미지 크기를 줄여 연산량을 크게 줄일 수 있다.



[그림 4] MaxPooling 연산


마지막으로, 반복적인 합성곱과 풀링을 거쳐 고차원적으로 압축된 특징 정보는 1차원 배열로 펼쳐져 (Flatten) 완전 연결층으로 전달되며, 최종적으로 소프트맥스(Softmax) 등의 활성화 함수를 통해 해당 이미지를 확률적으로 분류한다.



[그림 5] Fully Connected Layer


2. CNN 아키텍처 비교

VGG-16은 3x3 크기의 작은 필터를 깊게 올린 구조(16개 층)이 특징이다. 깊은 신경망을 통해 미세한 특징을 잘 잡아내어 높은 정확도를 보이지만, 파라미터 수가 약 1억 3천만 개로 매우 많아 연산량이 높고 메모리 소모가 크다는 단점이 있다.




[그림 6] VGG-16 아키텍처

MobileNet-V2는 임베디드 장치와 같은 제한된 컴퓨팅 환경을 위해 설계된 경량화 모델이다. 일반적인 Convolution 연산 대신 Depthwise Seperable Convolution(깊이별 분리 합성곱) 연산 기법을 이용하여 정확도를 최소화하면서 연산 속도를 향상시켰다.



[그림 7] MobileNet-V2 아키텍처

ResNet-18은 신경망이 깊어질수록 학습이 잘되지 않는 기울기 소실 문제를 해결하기 위해 Residual Learning(잔차 학습) 개념을 도입한 모델이다. Skip Connection을 통해 깊은 망에서도 효율적인 학습이 가능하다.



[그림 8] ResNet-18 아키텍처

III. Proposed Method


1. 전체 시스템 구성 및 개발 환경

본 연구에서 제안하는 딥러닝 기반 나사 결함 탐지 시스템은 크게 세 단계의 파이프라인으로 설계되었다.

첫째, 데이터 준비 단계이다. 전체 480장의 데이터를 학습용 425장(88.5%)과 독립 테스트용 55장(11.5%)으로 분할하였으며, 테스트 셋은 하이퍼파라미터 선택 과정 및 모델 재학습에서 완전히 격리하여 최종 일반화 성능 평가에만 사용하였다. 학습 과정에서 과적합을 방지하고 모델의 강건성을 향상시키기 위해 회전, 이동, 밝기 조정 등의 실시간 데이터 증강 기법을 파이프라인 내에 통합하여 적용하였다.

둘째, 모델 최적화 및 최종 학습 단계이다. 제조업 특유의 클래스 불균형 문제를 해소하고, 세 가지 CNN 아키텍처(VGG-16, ResNet-18, MobileNet-V2)의 성능을 객관적으로 비교하기 위해 체계적인 학습 전략을 도입하였다. 우선 Grid Search와 Stratified 5-Fold CV를 결합하여 모델별 최적의 불량 클래스 가중치를 탐색하였다. 이후 도출된 최적 가중치를 바탕으로 425장의 실험 데이터를 활용해 전체 데이터 재학습을 수행하여 최종 배포용 최적 모델을 구축하였다.

셋째, 종합 성능 평가 및 신뢰성 검증 단계이다. 앞서 격리해 둔 55장의 독립 테스트 셋을 활용하여 최종 모델의 실질적인 일반화 성능을 평가한다. 특히 F2-Score와 FPS를 핵심 평가 지표로 채택하였다. 이와 더불어 FASI 지표를 통해 가장 적합한 최종 모델을 확정한다. 마지막으로, 모델의 결함 판별 근거를 시각적으로 확인하기 위해 Grad-CAM 기법을 적용함으로써 인공지능 판단의 신뢰성을 검증하였다.



[그림 9] 전체 시스템 구성도

딥러닝 모델 학습 및 평가를 위한 하드웨어 환경은 Intel Core Ultra 9 285K CPU와 NVIDIA GeForce RTX 5080 GPU 시스템을 구축하여 사용하였다. 소프트웨어 환경으로는 Python 3.10.20과 PyTorch 2.10.0(cu128)을 핵심 프레임워크로 채택하였으며, 성능 평가 지표 산출 및 시각화를 위해 Scikit-learn, Matplotlib 라이브러리를 활용하였다.

2. 데이터 구성 및 전처리

본 연구의 모델 학습 및 성능 평가를 위해 Kaggle의 공개 데이터셋인 'Screw Anomalies Detection' 이미지를 활용하였다. 해당 데이터 셋은 본래 정상(Good) 데이터의 분포만을 학습하여 이상을 탐지하는 비지도 학습(Unsupervised Learning)을 목적으로 구축된 것이다. 그러나 산업 현장의 복잡한 결함 특징을 보다 명확히 추출하고 비지도 학습의 한계(미탐율 증가 및 분류 모호성)를 극복하기 위해, 본 연구에서는 정상품과 불량품의 특징을 모델에 직접 학습시키는 지도 학습(Supervised Learning) 체계에 맞추어 원본 데이터 셋을 전면 재구성하였다.

원본 데이터는 총 480개의 이미지로 구성되어 있으며, 결함의 형태에 따라 5가지의 세부 불량 유형(type 1~5)으로 나뉜다. 각 세부 유형은 나사의 끝부분, 나사 머리, 나사 목, 나사산 등의 물리적 파손 및 시점 변화를 포함한다.

분류	Type1	Type2	Type3	Type4	Type5
결함 상세 정의	나사 끝부분 휘어짐 및 끊어짐	나사 머리 깨짐	나사 목 깨짐	나사산 깨짐 (측면 시점)	나사산 깨짐 (상단 시점)
예시 이미지					

[표 1] 불량 데이터의 세부 유형

이진 분류 모델 학습 및 평가를 위해 전체 480장의 데이터 셋을 [표 2]와 같이 분할하였다. 실험의 객관성을 위해 최종 성능 평가를 위한 테스트 데이터 셋 55장을 사전에 분리하여 모든 학습 및 최적화 과정에서 배제하였다.

남은 425장의 데이터는 모델 개발 및 실험용 데이터 셋(Experimental Set)으로 정의하였다. 5.2절에서 수행하는 최적 하이퍼파라미터 탐색 단계에서는 이 Train과 Val 데이터를 통합하여 Stratified 5-Fold CV의 전체 폴로 활용한다. 이후 5.3절의 최종 모델 재학습 단계에서는 Train 데이터 340장을 이용해 모델의 가중치를 학습하고, Val 데이터 85장을 활용하여 학습 과정에서의 성능을 모니터링하였다.

구분	정상 (Good)	불량 (Bad)	세부 불량 분포 (Type 1 / 2 / 3 / 4 / 5)	합계	
Train	260	80	16 / 16 / 16 / 16 / 16	340	425
Val	65	20	4 / 4 / 4 / 4 / 4	85	
Test	36	19	4 / 4 / 5 / 3 / 3	55	
합계	361	119	24 / 24 / 25 / 23 / 23	480	

[표 2] 실험용 및 모델 재학습 데이터 셋

3. 데이터 증강

본 연구는 제한된 학습 데이터(425장)로 인한 과적합 문제를 완화하고 모델의 일반화 능력을 향상시키기 위해 데이터 증강 기법을 적용하였다.

학습 단계에서는 데이터를 사전에 복제하여 저장하는 오프라인 방식 대신, 매 이터레이션마다 이미지를 무작위로 변형하여 입력하는 온라인 데이터 증강 기법을 적용하였다. 이를 통해 모델이 동일한 이미지에 대해 매번 다른 변형 상태를 학습하게 함으로써 강건한 특징 추출을 유도하였다. 반면, 검증 및 테스트 단계에서는 데이터의 일관성을 확보하고 모델의 순수한 예측 성능을 측정하기 위해 최소한의 증강 작업만을 수행하였다.

구분	적용 기법	상세 설명
공통	Resize	입력 크기를 (256, 256) 픽셀로 조정
	Normalize	정규화
Train	RandomRotation	$\pm 180^\circ$ 무작위 회전. 회전 시 발생하는 여백은 원본 배경색인 RGB(196, 196, 196)로 채움
	RandomResizeCrop	0.8 ~ 1.0 비율로 무작위 크롭 후 (224, 224)로 재조정.
	Horizontal/Vertical Flip	좌우(p=0.5) 및 상하(p=0.5) 반전
	Color Jitter	밝기 및 대비를 0.3 범위 내 무작위 조정
Val, Test	Center Crop	중심부를 기준으로 (224, 224) 크롭

[표 3] 단계별 데이터 증강 기법 상세 설명



[그림 10] Type 1 이미지의 데이터 증강 예시

4. 딥러닝 모델 전이 학습 및 아키텍처 재구성

본 연구에서는 480장이라는 한정된 제조업 데이터 셋의 물리적 한계를 극복하기 위해, 사전 학습된 VGG-16, ResNet-18, MobileNet-V2 아키텍처를 기반으로 한 전이 학습(Transfer Learning) 기법을 적용하였다. 이를 위해 대규모 이미지 데이터 셋(ImageNet)으로 사전 학습된 가중치(Pre-trained Weights)를 로드하여, 모델 하위 층(Lower layers)에 내재된 범용적인 에지(Edge) 및 질감(Texture) 등 시각적 특징 추출 능력을 그대로 활용하였다.

특히, 기존의 사전 학습 모델들은 1,000개의 범용 사물 클래스를 분류하도록 설계되어 있으므로, 이를 나사 결함 탐지 목적에 맞게 재설계하는 미세 조정(Fine-tuning) 과정이 필수적이다. 따라서 각 모델의 최상단에 위치한 기존 완전 연결 층(Fully Connected Layer)을 제거하고, 출력 노드의 개수를 정상(Good)과 불량(Bad)을 나타내는 2개로 변경한 새로운 분류 헤드(Classification Head)를 결합하여 이진 분류 아키텍처를 완성하였다.

5. 학습 전략

본 절에서는 제안 모델의 일반화 성능과 학습 효율을 높이기 위한 세부 전략을 다룬다. 공정한 성능 비교를 위해 세 가지 아키텍처(VGG-16, ResNet-18, MobileNet-V2)에 완전히 동일한 실험 환경(하드웨어, 데이터 분할, 하이퍼파라미터 등)을 적용하여 결과의 객관성을 확보하였다. 구체적인 학습 및 최적화 전략은 다음과 같다.

5.1 클래스 불균형 해소 전략: Weighted Cross Entropy Loss

학습 데이터는 클래스 불균형이 존재한다. 이러한 불균형은 모델이 다수 클래스(정상)에 편향되어 학습되는 문제를 야기한다. 이러한 문제를 근본적으로 해결하기 위해, Loss 계산 시 불량 데이터에 더 높은 가중치(Penalty)를 부여하는 Weighted Cross Entropy Loss를 도입하였다. 수식은 다음과 같다.

$$WCEL = - \sum_{i=1}^C w_i y_i \log(\hat{y}_i)$$

여기서 w_i 는 각 클래스에 부여된 가중치를 의미한다. 본 실험에서는 정상 클래스의 가중치를 1.0으로 고정하고, 불량 클래스의 가중치를 최적화해야 할 하이퍼파라미터로 설정하였다.

5.2 최적 하이퍼파라미터 탐색: Grid Search 및 Stratified 5-Fold CV

불량 클래스 가중치를 객관적으로 도출하기 위해, 본 연구에서는 Grid Search와 Stratified 5-Fold CV를 결합하여 실험을 설계하였다. 이는 단일 Validation Set에 모델이 과적합(Overfitting)되어 특정 데이터 분할에만 유리한 편향된 가중치가 선정되는 오류를 방지하기 위함이다.


이를 위해 전체 학습 데이터를 클래스 비율(3.25:1)이 동일하게 유지되도록 5개의 Fold로 분할하였다. 각 탐색 단계에서 4개의 Fold는 학습에, 나머지 1개의 Fold는 검증에 할당하여 총 5회의 독립적인 학습 및 평가를 수행하였다.

가중치 탐색은 1.0부터 5.0까지 0.5 간격으로 진행하였다. 학습 과정 중 검증 데이터 셋을 통해 달성한 최고 성능의 F2를 해당 Fold의 대표 성능 지표(Max F2)로 기록하였다. 이후, 특정 Fold에서 우연히 달성된 최고 성능에 의존하지 않기 위해, 5개의 독립된 Fold에서 각각 기록된 최고 F2-Score들의 평균(Mean Max F2)을 해당 Weight에 대한 최종 성능 지표로 산출한다.

또한, 특정 Fold에서 모델이 과도하게 학습되어 일반화 성능을 잃는 것을 방지하기 위해 조기 종료(Early Stopping) 기법을 도입하였다. 매 epoch마다 Val 데이터 셋의 F2-Score를 모니터링하였으며, 10 epoch(Patience=10) 동안 F2-Score의 성능 개선이 관찰되지 않을 경우 해당 Fold의 학습을 즉각 중단하도록 설정하였다.

가중치 탐색 (Grid Search)

대상 가중치(w): 1.0, 1.5, . . . , 5.0



[결과 산출] 5개 Fold의 Max F2 평균 계산 (Mean Max F2)

[최적 W 확정] Mean Max F2가 가장 높은 Weight = 최적 W 선정

[그림 11] Grid Search 및 Stratified K-Fold 도식화

5.3 전체 데이터 재학습 및 최종 모델 구축

최종 모델은 특정 데이터 분할에 의존하지 않는 보편적인 성능을 확보하기 위해 새로운 학습 과정을 거쳤다. 최종 모델 구축을 위해 학습 데이터(Train) 340장은 모델의 가중치를 직접 업데이트하는 데 사용되었으며, 별도의 검증 데이터(Val) 85장은 학습 중 실시간 성능을 모니터링하여 최적의 수렴 지점을 결정하는 용도로 활용되었다.

특히, 과적합을 방지하기 위해 이 검증 데이터(85장)를 바탕으로 조기 종료(Early Stopping)를 모니터링하였으며, 학습 과정 중 검증 F2-Score가 가장 우수했던 시점의 가중치를 최종적으로 복원하였다. 재학습 및 최적화 과정을 거쳐 가장 높은 검출 신뢰도를 확보한 이 결과물을 각 아키텍처의 최종 최적 모델(Best Model)로 확정하였다.

5.4 하이퍼파라미터 탐색 및 모델 재학습 하이퍼파라미터

5.2절의 교차 검증(CV)을 통한 가중치 탐색 과정과 5.3절의 최종 모델 재학습 과정에서, 탐색 대상인 불량 클래스 가중치를 제외한 모든 하이퍼파라미터와 최적화 설정을 동일하게 통제하였다.

적용된 세부 하이퍼파라미터 설정은 다음과 같다.

파라미터	설정 값	비고
Optimizer	Adam	초기 학습률 = 10^{-4}
Loss Function	Weighted Cross Entropy Loss	불량 클래스 가중치는 5.2절의 탐색 결과 적용
Batch Size	16	메모리 한계 및 안정성 고려
Epochs	40	Early Stopping 적용으로 조기 종료 허용
Early Stopping	patience=10	Val 데이터셋의 F2-Score 기준 모니터링

[표 4] 공통 하이퍼파라미터 설정

6. 평가 계획

6.1 성능 평가 및 지표

5.3절의 재학습을 통해 확정된 각 아키텍처별 최적 모델(Best Model)들을 대상으로, 모델 학습 및 하이퍼파라미터 튜닝 전 과정에서 격리되었던 독립 테스트 데이터 셋(Test Set, 55장)을 활용하여 최종 성능 평가를 수행한다.

6.2 Confusion Matrix 기반 정량적 지표

모델의 성능 평가를 위해 단순 정확도(Accuracy)가 아닌, 실제 불량품을 놓치지 않고 찾아내는 비율인 재현율(Recall)을 최우선으로 고려한다. 이를 위해 정밀도(Precision)와 재현율을 결합하되, 재현율에 2배의 가중치를 부여하는 F2-Score를 모델의 핵심 성능 지표로 채택하였다. Confusion Matrix을 기반으로 한 각 지표의 산출 수식은 다음과 같다. 여기서 TP는 불량을 불량으로 정확히 예측한 수, FP는 정상을 불량으로 오진한 수, FN은 불량을 정상으로 오진한 수를 의미한다.

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$F2-Score = \frac{5 \times Precision \times Recall}{4 \times Precision + Recall}$$

6.3 추론 속도 및 FPS 지표

실시간 탐지 능력을 검증하기 위해 모델의 추론 속도(Inference Speed)와 초당 처리 프레임 수(FPS)를 측정하였다. 추론 속도는 단일 이미지(Batch Size=1)가 모델에 입력되어 최종 결함 여부가 출력되기까지 소요되는 시간(ms)으로 정의하였으며, 하드웨어 성능에 따른 편차를 통제하기 위해 동일한 CPU 환경에서 실행하여 산출하였다. FPS는 다음 수식을 통해 계산된다.

$$FPS = \frac{1000}{\text{Inference Time (ms)}}$$

6.4 종합 성능 평가 지표: FASI

F2-Score와 FPS를 모두 충족하는 적정선의 모델을 선택해야 하므로, 정확도와 실시간성을 단일 수치로 비교할 수 있는 독자적인 종합 성능 지표 FASI(Factory Automation Suitability Index)를 제안한다. FASI는 모델의 F2-Score와 정규화된 FPS를 기반으로 산출되며, 그 수식은 다음과 같다.

$$FASI = (\alpha \times F_2 - Score) + ((1 - \alpha) \times FPS_{norm})$$

α 는 제조 공정의 특성에 따라 정확도와 속도 중 어느 곳에 더 가중치를 둘 것인지 결정하는 조정 계수이며, 본 실험에서는 $\alpha=0.7$ 로 설정하여 미탐 방지에 더 높은 비중을 두었다.

IV. Experimental Results

1. 최적 클래스 가중치 탐색 결과

모델	Best Weight	Fold 별 Max F2 (Fold 1 / 2 / 3 / 4 / 5)	평균 F2 (Mean Max F2)	표준편차
ResNet-18	2.0	0.8120 / 0.9091 / 0.8407 / 0.8261 / 0.8547	0.8485	0.0335
MobileNet-V2	2.5	0.9174 / 0.8879 / 0.8095 / 0.7724 / 0.9524	0.8679	0.0671
VGG-16	5.0	0.6061 / 0.6061 / 0.6115 / 0.6135 / 0.6173	0.6129	0.0044

[표 5] 모델별 최적 클래스 가중치 탐색 결과


가장 먼저 ResNet-18은 가중치 2.0에서 평균 F2-Score 0.8485를 기록하며 준수한 성능을 보였다. 특히 주목할 부분은 Fold 간 성능 편차를 나타내는 표준편차가 0.0335로, 학습된 모델 중 가장 낮았다는 점이다.

경량화 아키텍처인 MobileNet-V2는 가중치 2.5에서 평균 F2-Score 0.8679를 기록하며 세 모델 중 가장 높은 성능을 달성하였다. 특정 Fold에서는 F2-Score가 0.9524에 달할 정도로 잠재력이 뛰어났다. 그러나 표준편차가 0.0671로 ResNet-18에 비해 약 2배가량 높게 측정되었다. 이는 모델이 검증 데이터 셋의 분포에 다소 민감하게 반응하여 성능의 기록이 존재함을 의미하며, 안정성 측면에서 추가적인 검증이 필요함을 시사한다.

앞선 두 모델과 대조적으로, VGG-16은 평균 F2-Score 0.6129에 그치며 가장 낮은 성능을 보였다. 최적 가중치로 도출된 5.0은 본 실험의 탐색 상한치로, 이는 불량 클래스에 극단적인 패널티를 부여해야만 간신히 오진을 방어할 수 있었음을 의미한다. 0.0044라는 극도로 낮은 표준편차 또한 모델이 안정적이라는 뜻이 아니라, 모델이 데이터의 특징을 학습하는 데 실패하고 모든 Fold에서 일관되게 낮은 성능에 갇혀버린 local minima 상태임으로 해석할 수 있다.

2. 최종 모델 Train/Val Loss Curve

5.2절에서 도출된 각 아키텍처별 최적 불량 클래스 가중치를 적용하여, 425장의 실험 데이터(Train 340장, Validation 85장)로 최종 모델을 재학습한 과정의 Train/Val Loss Curve를 분석한다.



[그림 12] Train / Val Loss Curve

ResNet-18의 경우, Train Loss는 꾸준히 우하향하며 0.2 부근까지 도달하여 학습 자체는 원활하게 진행되었음을 알 수 있다. 그러나 Val Loss 곡선에서 에포크 20 이후로 주기적이고 강한 진동이 관찰되었다. 이는 모델이 훈련 데이터의 특징을 잡아내고는 있으나, 85장에 불과한 소규모 검증 데이터 셋의 특정 배치나 어려운 샘플에 대해 다소 민감하게 반응하고 있음을 시사한다. 그럼에도 불구하고 전체적인 추세선은 하향하고 있으므로, 최적 가중치를 포착하는 전략이 유효하게 작용했음을 확인할 수 있다.

MobileNet-V2는 세 가지 모델 중 손실 곡선이 가장 이상적인 수렴 형태를 보였다. Train Loss와 Val Loss가 에포크 진행에 따라 동반하여 부드럽게 하락하고 있으며, 두 곡선 간의 격차가 학습 종료 시점까지 매우 좁게 유지되었다.

VGG-16의 곡선은 모델이 데이터에 전혀 학습하지 못하고 실패한 전형적인 과소적합 및 최적화 실패 패턴을 보여준다. Train Loss가 0.6~0.7 구간에서 더 이상 하락하지 않고 정체되어 있으며, Val Loss는 에포크 20 부근에서 최대 1.5까지 치솟는 극심한 발산 현상을 나타냈다.

3. 최종 모델의 테스트 데이터 평가 성능 및 추론 속도

모델	Test Precision	Test Recall	Test F2	CPU FPS
ResNet-18	0.9500	1.0000	0.9896	88.8
MobileNet-V2	0.8571	0.6316	0.6667	82.9
VGG-16	0.3333	0.5789	0.5046	24.2

[표 6] 모델별 테스트 데이터 평가 성능 및 추론 속도

독립된 테스트 셋을 통해 최종 모델의 실제 일반화 성능을 검증하였으며, CPU 환경을 기준으로 모델의 추론 속도(FPS)를 측정하였다.

결합 탐지 성능 측면에서 ResNet-18이 test F2-score 0.9896으로 가장 우수한 성능을 기록하였다. 특히 Recall은 1.0을 기록하여, 테스트 셋 내의 불량품을 단 한 건의 누락 없이 100% 검출해 내는 데 성공하였다. 또한, 정상품을 불량으로 오진하는 비율을 나타내는 정밀도(Precision) 역시 0.9500으로 매우 높게 기록하였다. 결과적으로 0.9896이라는 높은 F2-Score를 달성하였다.

교차 검증 단계에서 ResNet-18보다 높은 고점을 보였던 MobileNet-V2는 테스트 셋에서 재현율이 0.6316으로 급락하며 F2-Score 0.6667에 그쳤다. VGG-16의 경우 정밀도 0.3333, F2-Score 0.5046을 기록하였으며, 이는 앞선 손실 곡선(Loss Curve) 분석에서 확인된 바와 같이 망이 깊어짐에 따른 기울기 소실 및 학습 수렴 실패로 인해 유의미한 성능을 확보하지 못했음을 시사한다.

추론 속도 측면에서는 ResNet-18이 CPU 기준 88.8 FPS로 가장 빠른 처리 속도를 보였다. MobileNet-V2는 82.9 FPS로 ResNet-18 대비 약 6.6% 느렸으며, 경량 모델임에도 불구하고 CPU 환경에서는 ResNet-18보다 추론 속도가 느린 것으로 나타났다. 이러한 현상은 모델 구조 및 구현 방식에 기인할 가능성이 있으며, 이에 대한 추가적인 분석이 필요하다.

VGG-16은 24.2 FPS로 ResNet-18 대비 약 73% 느려, 세 모델 중 가장 낮은 추론 속도를 기록하였다. 이는 138M 파라미터의 대용량 모델 특성상 메모리 대역폭 소모가 크고 연산량이 많아 발생한 결과로 해석된다.

4. FASI 기반 최종 모델 선정

모델	F2-Score (0.7)	FPS_{norm} (0.3)	FASI ($\alpha = 0.7$)
ResNet-18	0.9896	1.0	0.9927
MobileNet-V2	0.6667	0.9336	0.7468
VGG-16	0.5046	0.2804	0.4373

[표 7] 모델별 FASI

탐지 성능(F2-score)과 실시간 추론 속도(정규화된 FPS)를 통합한 FASI 지표 기반의 최종 모델 선정 결과이다.


ResNet-18이 FASI 0.9134로 가장 높은 종합 성능을 기록하여 최종 우수 모델로 선정되었다. F2-score 0.9896으로 결함 탐지 성능에서 비교 모델 대비 상대적으로 우수했을 뿐만 아니라, FPS_norm 1.0으로 가장 빠른 추론 속도를 보여 성능과 속도 두 측면 모두에서 최고를 달성하였다.

MobileNet-V2는 FASI 0.7468로 2위를 기록하였다. F2-score는 0.6667로 ResNet-18 대비 약 33% 낮았으나, FPS_norm 0.9336으로 추론 속도는 ResNet-18과 유사한 수준을 유지하였다.

VGG-16은 FASI 0.4373으로 가장 낮은 점수를 기록하였다. F2-score 0.5046으로 결함 탐지 성능이 ResNet-18 대비 약 49% 낮았으며, FPS_norm 0.2804로 추론 속도 또한 ResNet-18 대비 약 72% 느렸다.

5. Grad-CAM 시각화 분석

RESNET18 - Prediction vs Grad-CAM



[그림 13] ResNet-18 Grad-CAM 시각화 결과

그림 13는 최종 선정된 ResNet-18 모델의 결함 탐지 메커니즘을 검증하기 위해 Grad-CAM 기법을 적용한 결과를 나타낸다. 각 클래스 별로 추출한 3장의 테스트 이미지에 대해 모델이 주목한 영역을 히트맵으로 시각화하였으며, 빨간색 영역일수록 모델의 예측에 큰 영향을 미친 부분을 의미한다.

정상품(Good)은 3장 모두 정확히 정상으로 예측하였다(3/3). 그러나 일부 샘플에서 나사 표면 특정 영역이 붉게 활성화된 점이 다소 아쉬운 부분이다. 이상적으로는 결함이 없으므로 activation이 고르게 분포해야 하나, 모델이 나사산이나 금속 반사 등 정상 범위 내 미세한 특징에도 민감하게 반응한 것으로 해석된다.

Type 1 결함 이미지 3장은 모델에 의해 모두 '불량(BAD)'으로 정확하게 분류되었다. 그러나 Grad-CAM을 통한 Activation 분석 결과, 나사 몸체나 배경 영역으로 활성화가 분산되는 양상을 보였다. 즉, 모델이 결함의 존재 여부는 정확히 판별하였으나, 그 판단의 시각적 근거는 부정확했다.

Type 2(나사 머리 불량) 및 Type 3(나사 목 불량)은 각각 3장씩 총 6장 모두 정확히 불량으로 예측하였다(6/6). 픽셀 밝기 및 텍스처 변화가 뚜렷한 결함 유형을 가장 효과적으로 감지하는 것으로 확인되었다. Type 2의 경우 스크래치가 발생한 표면 부위에 강한 activation이 집중되었으며, Type 3 역시 파인 영역을 정확히 포착하였다.

Type 4 역시 3장 모두 불량으로 정확히 판정하였으나, Grad-CAM 분석에서는 Type 1과 유사하게 형태 기반 탐지의 한계가 뚜렷하게 관찰되었다. 나사를 측면에서 촬영함에 따라 결함 부위(나사 산)가 온전한 나사산 사이에 가려져 시각적으로 명확히 드러나지 않았으며, 그 결과 활성화 영역 역시 특정 결함 위치에 집중되지 못하고 나사 배경이나 나사 목 노이즈에 넓게 흩어지는 패턴을 보였다.

Type 5는 3장 모두 불량으로 정확히 예측됨과 동시에, 앞선 Type 4와 대조적으로 명확하고 이상적인 활성화 패턴을 보였다. 나사를 상단 시점에서 촬영하여 파손된 나사산 부위가 윗면에 직접 노출되었고, Grad-CAM 상에서도 해당 손상 영역에만 강한 붉은색 활성화가 정확히 타겟팅되었다.

종합적으로, ResNet-18은 텍스처 변화가 뚜렷한 결함(Type 2, 3, 5)에 대해서는 높은 분류를 유지함에도 불구하고 나사의 형태 결함(Type 1, 4)에 대해서는 인공지능 판단 근거의 신뢰성을 담보하기 어려운 현상이 관찰되었다.

V. Conclusions

1. 주요 발견 및 기여

본 연구는 제한된 데이터 환경에서 CNN 기반 결함 탐지 모델의 성능 비교를 수행했다는 점에서 의의를 가진다.

첫째, ResNet-18이 FASI 0.9927로 최고 성능을 기록하여 최종 모델로 선정되었다. Test F2-score 0.9896, CPU 기준 88.8 FPS를 달성하여 결함 탐지 정확도와 실시간 처리 속도 양 측면에서 가장 균형 잡힌 성능을 보였다. 이는 11M 파라미터의 적절한 모델 크기와 residual connection 구조가 소규모 데이터 셋 환경에서 학습 안정성과 일반화 성능을 동시에 확보하는 데 가장 효과적임을 입증하였다.

둘째, 경량화 모델인 MobileNet-V2는 학습 과정에서 안정적으로 수렴하였으나, 테스트 셋에서 재현율이 0.6316으로 급락하고 추론 속도(82.9 FPS)마저 ResNet-18에 역전당하는 한계를 노출했다.

셋째, 대용량 모델인 VGG-16은 최적 가중치 5.0 상한선에서도 기울기 소실 문제로 인한 학습 수렴 실패를 보였다.

넷째, CV 및 Weighted Cross Entropy Loss를 데이터 부족, 불균형 해소 전략을 제안하고 적용하였다. 교차 검증 결과, 최적 가중치 2.0(ResNet-18 기준)에서 최고 성능을 달성하였다.

다섯째, Grad-CAM 시각화를 통해 CNN의 결함 탐지 메커니즘을 심층 분석하였다. 텍스처 기반 결함(Type 2, 3, 5)에서는 명확한 위치 기반 탐지를 보인 반면, 형태 기반 결함(Type 1, 4)에서는 모델이 불량 여부 분류에는 성공하였음에도 활성화 영역이 엉뚱한 곳으로 분산되는 국소화 실패 현상이 관찰되었다.

2. 연구 한계점

본 연구는 다음과 같은 한계를 지닌다.

첫째, 데이터 규모가 전체 480장으로 제한되어 모델의 일반화 능력이 충분히 발휘되지 못했을 가능성이 있다. 특히 결함 클래스당 20~25장으로 소수 클래스 학습에 한계가 존재하였으며, 특히 테스트 셋이 55장(Good 36장, Bad 19장)에 불과해 모델의 실제 성능을 충분히 검증하기 어려웠다.

둘째, Grad-CAM 시각화에서 현재 CNN 구조로는 제조 현장에서 발생 가능한 모든 결함 유형을 안정적으로 탐지하기 어려우며, 추가적인 구조적 개선이 필요하다.

셋째, FASI 지표의 가중치($\alpha=0.7$)는 본 연구의 나사 결함 탐지 환경에서 설정되었으며, 향후 다양한 제조 환경에서의 적용을 통해 범용적인 가중치 결정 방법론 및 다른 세부 지표를 도출하는 연구가 필요하다.

3. 향후 연구 방향

본 연구의 한계를 극복하고 성능을 향상시키기 위한 향후 연구 방향은 다음과 같다.

첫째, 데이터 확보가 최우선 과제이다. 클래스당 최소 100장 이상으로 데이터를 확대하여 모델의 일반화 능력을 강화하고, 특히 Type 1과 같이 탐지가 어려운 결함 유형의 샘플을 추가 확보하여 학습 불균형을 개선해야 한다.

둘째, CBAM과 같은 Attention 메커니즘을 도입하여 CNN의 형태 인식 한계를 보완할 필요가 있다. Spatial Attention을 통해 GAP가 소실시키는 위치 정보를 보존함으로써 Type 1, 4와 같은 형태 기반 결함의 탐지 성능을 향상시킬 수 있을 것으로 기대된다.

셋째, 본 연구에서 제안한 FASI 지표의 범용성 및 실용성을 검증하고, 최적 가중치를 도출하는 후속 연구가 필요하다.

넷째, EfficientNet-B0/B1과 같이 정확도와 효율성이 균형 잡힌 최신 아키텍처를 비교군에 추가하거나, Vision Transformer 기반 모델을 도입하여 전역적 형태 인식 능력을 강화하는 방향도 고려할 수 있다.

VI. Reference

- [1] Liu, L., Zhao, J., Chen, Z., Zhao, B., & Ji, Y. (2022). A new bolt defect identification method incorporating attention mechanism and wide residual networks. *Sensors*, 22(19), 7416.
- [2] Song, L., Li, X., Yang, Y., Zhu, X., Guo, Q., & Yang, H. (2018). Detection of micro-defects on metal screw surfaces based on deep convolutional neural networks. *Sensors*, 18(11), 3709.
- [3] Ronneberger, O., Fischer, P., & Brox, T. (2015, October). U-net: Convolutional networks for biomedical image segmentation. In *International Conference on Medical image computing and computer-assisted intervention* (pp. 234–241). Cham: Springer international publishing.
- [4] Aydin, Cem Savas, and Abdulkader Alwer. (2025). Defect-detection in casting products using grid search augmented PCA CNN hybrid model.
- [5] Lee, S. B., & Lee, S. S. (2022). 합성곱 신경망을 이용한 손상된 볼트의 이미지 분류. *Journal of Aerospace System Engineering*, 16(4), 109–115.
- [6] 노은솔, 이사랑, & 홍석무. (2021). 전이학습 기반 CNN 을 통한 풀림 방지 코팅 볼트 이진 분류에 관한 연구. *한국산학기술학회 논문지*, 22(2), 651–658.
- [7] 김동현. (2023). 자동차 액션로더 제조 불량품 검사를 위한 AI 딥러닝 기반 검사시스템 구현. *전기학회논문지*, 72(12), 1714–1721.